

# Sprawozdanie z projektu: klasyfikacja homomorficzna

## Autorzy

Jakub Karczewski, Piotr Sielchanowicz, Michał Kowalczyk

## 1. Cel projektu

Celem projektu było sprawdzenie, czy można wykonać etap predykcji modelu klasyfikacyjnego na danych zaszyfrowanych homomorficznie przy pomocy schematu szyfrowania CKKS.

Główna idea działania:

- 1. Trenowany jest klasyczny model liniowy na danych jawnych.
- 2. Próbką testowa jest szyfrowana jako wektor CKKS.
- 3. Model wykonuje homomorficznie obliczenie score'u klasy:

```
score = w * x + b
```

- 4. Wyniki score pozostają zaszyfrowane.
- 5. Po odszyfrowaniu wyników wybierana jest klasa z najwyższym score'em.

## 2. Wykorzystane narzędzia

W projekcie użyto:

- Python,
- TenSEAL,
- NumPy,
- scikit-learn,
- Matplotlib,
- Seaborn,
- multiprocessing dla przyspieszenia testu MNIST.

Schemat szyfrowania:

| Parametr            | Wartość          |
|---------------------|------------------|
| Schemat             | CKKS             |
| poly_modulus_degree | 8192             |
| coeff_mod_bit_sizes | [60, 40, 40, 60] |
| global_scale        | 2**40            |

CKKS jest schematem przybliżonym, dlatego wyniki po odszyfrowaniu mogą minimalnie różnić się od wyników liczonych bez szyfrowania.

### 3. Eksperyment 1: klasyfikacja binarna Iris

Pierwszy eksperyment dotyczył binarnej klasyfikacji zbioru Iris. Użyto dwóch klas oraz czterech cech. Model regresji logistycznej został wytrenowany na danych jawnych, a następnie pojedyncza próbka testowa została zaszyfrowana i sklasyfikowana homomorficznie.

### 4. Eksperyment 2: klasyfikacja wieloklasowa Iris

Drugi eksperyment rozszerzył podejście na pełny zbiór Iris z trzema klasami. Dla każdej klasy obliczany był osobny score:

$$\text{score}_i = w_i * x + b_i$$

Po odszyfrowaniu wyników wybierano klasę z największą wartością score. Dla przykładowej próbki notebook zwrócił:

| Klasa | Score po odszyfrowaniu |
|-------|------------------------|
| 0     | -3.0578                |
| 1     | 2.3249                 |
| 2     | 0.7329                 |

Predykcja:

| Element            | Wartość |
|--------------------|---------|
| Przewidziana klasa | 1       |
| Prawdziwa klasa    | 1       |

Metryki klasyfikacji homomorficznej dla całego testu Iris:

| Metryka            | Wartość |
|--------------------|---------|
| Accuracy           | 1.0000  |
| Precision weighted | 1.0000  |
| F1 weighted        | 1.0000  |

Powodem tego rezultatu było najpewniej to, że zbiór nie jest zbyt skomplikowany do klasyfikacji, bo klasy są łatwo separowalne.

### 5. Eksperyment 3: klasyfikacja MNIST

Charakterystyka danych:

| Cecha            | Wartość |
|------------------|---------|
| Liczba próbek    | 70000   |
| Liczba cech      | 784     |
| Zbiór treningowy | 60000   |
| Zbiór testowy    | 10000   |
| Liczba klas      | 10      |

Model jawny został wytrenowany za pomocą `SGDClassifier` z funkcją straty `log_loss`.

### 5.1. Wyniki modelu jawnego na pełnym teście MNIST

| Metryka            | Wartość |
|--------------------|---------|
| Accuracy           | 0.9155  |
| Precision weighted | 0.9156  |
| Recall weighted    | 0.9155  |
| F1 weighted        | 0.9152  |

Czas treningu modelu jawnego wyniósł `3.71 s`.

### 5.2. Podzbiór do testu homomorficznego

Ze względu na koszt obliczeń homomorficznych test CKKS wykonano na zbalansowanym podzbiorze testowym MNIST:

| Parametr               | Wartość |
|------------------------|---------|
| Liczba klas            | 10      |
| Liczba próbek na klasę | 200     |
| Łączna liczba próbek   | 2000    |

Dla każdej próbki szyfrowano wektor 784 pikseli, liczone score'y klas, odszyfrowywano wyniki i wybierano klasę przez `argmax`.


### 5.3. Wyniki klasyfikacji homomorficznej MNIST

| Metryka            | Wartość |
|--------------------|---------|
| Accuracy           | 0.8910  |
| Precision weighted | 0.8913  |
| Recall weighted    | 0.8910  |
| F1 weighted        | 0.8904  |

Czas wykonania(głównie deszyfrowania) przyspieszony przy pomocy multiprocessingu:

| Miara                                      | Wartość  |
|--------------------------------------------|----------|
| Liczba procesów                            | 4        |
| Całkowity czas klasyfikacji homomorficznej | 210.06 s |
| Średni czas na próbkę                      | 0.1050 s |

Macierz pomyłek dla MNIST CKKS:



6. Porównanie modelu jawnego i homomorficznego na tym samym podzbiorze

Porównanie nie odnosi się do pełnego testu MNIST, tylko dokładnie do tych samych 2000 próbek, które zostały poddane deszyfrowaniu.

Metryki modelu jawnego na podzbiorze:

| Metryka            | Wartość |
|--------------------|---------|
| Accuracy           | 0.8910  |
| Precision weighted | 0.8913  |
| Recall weighted    | 0.8910  |
| F1 weighted        | 0.8904  |

Porównanie predykcji:

| Miara                                       | Wartość |
|---------------------------------------------|---------|
| Zgodność predykcji jawnych i zaszyfrowanych | 1.0000  |
| Liczba różnych predykcji                    | 0       |

Oznacza to, że dla wybranego podzbioru 2000 próbek predykcje po obliczeniach CKKS były identyczne z predykcjami modelu jawnego. Nie oznacza to jednak, że model osiąga 100% skuteczności względem etykiet prawdziwych. Skuteczność względem etykiet wynosi 0.8910, a zgodność 1.0000 dotyczy tylko porównania dwóch trybów inferencji: jawnego i homomorficznego.

## 7. Wnioski

1. Szyfrowanie homomorficzne CKKS pozwala wykonać liniową część predykcji bez odszyfrowywania danych wejściowych.
2. Dla modeli liniowych, takich jak regresja logistyczna lub liniowy klasyfikator SGD, obliczenie  $w \cdot x + b$  dobrze pasuje do operacji wspieranych przez CKKS.
3. Na zbiorze Iris klasyfikacja homomorficzna dała poprawne wyniki i pełną skuteczność na testowanym zbiorze.
4. Na podzbiorze MNIST predykcje homomorficzne były zgodne z predykcjami modelu jawnego w 100% przypadków.
5. Błędy numeryczne CKKS były bardzo małe i nie zmieniły decyzji klasyfikatora w badanym teście.
6. Głównym ograniczeniem jest koszt obliczeniowy. Klasyfikacja 2000 próbek MNIST z użyciem 4 procesów trwała 210.06 s.

## 8. Podsumowanie

Projekt potwierdza, że można wykonać inferencję prostego klasyfikatora liniowego na danych zaszyfrowanych. Dla testowanego podzbioru MNIST wyniki CKKS po odszyfrowaniu były identyczne z predykcjami modelu jawnego, a błąd numeryczny był pomijalny z punktu widzenia decyzji klasyfikacyjnej. Jednocześnie rozwiązanie jest znacznie wolniejsze (ze względu na złożoność obliczeniową deszyfrowania) niż klasyczna predykcja na danych jawnych, dlatego w praktyce wymaga ograniczania liczby próbek, równoleglenia obliczeń lub dalszej optymalizacji.