

Sprawozdanie z projektu: klasyfikacja homomorficzna

Autorzy

Jakub Karczewski, Piotr Sielchanowicz, Michał Kowalczyk

1. Cel projektu

Celem projektu było sprawdzenie, czy można wykonać etap predykcji modelu klasyfikacyjnego na danych zaszyfrowanych homomorficznie przy pomocy schematu szyfrowania CKKS.

Główna idea działania:

1. Trenowany jest klasyczny model liniowy na danych jawnych.
2. Próbką testowa jest szyfrowana jako wektor CKKS.
3. Model wykonuje homomorficznie obliczenie score'u klasy:

$$\text{score} = w * x + b$$

4. Wyniki score pozostają zaszyfrowane.
5. Po odszyfrowaniu wyników wybierana jest klasa z najwyższym score'em.

2. Wykorzystane narzędzia

W projekcie użyto:

- Python,
- TenSEAL,
- NumPy,
- scikit-learn,
- Matplotlib,
- Seaborn,
- multiprocessing dla przyspieszenia testu MNIST.

Schemat szyfrowania:

Parametr	Wartość
Schemat	CKKS
poly_modulus_degree	8192
coeff_mod_bit_sizes	[60, 40, 40, 60]
global_scale	2**40

CKKS jest schematem przybliżonym, dlatego wyniki po odszyfrowaniu mogą minimalnie różnić się od wyników liczonych bez szyfrowania.

3. Eksperyment I: klasyfikacja binarna Iris

Pierwszy eksperyment dotyczył binarnej klasyfikacji zbioru Iris. Użyto dwóch klas oraz czterech cech. Model regresji logistycznej został wytrenowany na danych jawnych, a następnie pojedyncza próbka testowa została zaszyfrowana i sklasyfikowana homomorficznie.

4. Eksperyment II: klasyfikacja wieloklasowa Iris

Drugi eksperyment rozszerzył podejście na pełny zbiór Iris z trzema klasami. Dla każdej klasy obliczany był osobny score:

$$\text{score}_i = w_i * x + b_i$$

Po odszyfrowaniu wyników wybierano klasę z największą wartością score. Dla przykładowej otrzymano wynik:

Klasa	Score po odszyfrowaniu
0	-3.0578
1	2.3249
2	0.7329

Predykcja:

Element	Wartość
Przewidziana klasa	1
Prawdziwa klasa	1

Metryki klasyfikacji homomorficznej dla całego testu Iris:

Metryka	Wartość
Accuracy	1.0000
Precision weighted	1.0000
F1 weighted	1.0000

Powodem tego rezultatu było najpewniej to, że zbiór nie jest zbyt skomplikowany do klasyfikacji, bo klasy są łatwo separowalne.

5. Eksperyment III: klasyfikacja MNIST

Charakterystyka danych:

Cecha	Wartość
Liczba próbek	70000
Liczba cech	784
Zbiór treningowy	60000
Zbiór testowy	10000
Liczba klas	10

Model jawny został wytrenowany za pomocą `SGDClassifier` z funkcją straty `log_loss`.

5.1. Wyniki modelu jawnego na pełnym teście MNIST

Metryka	Wartość
Accuracy	0.9155
Precision weighted	0.9156
Recall weighted	0.9155
F1 weighted	0.9152

Czas treningu modelu jawnego wyniósł `3.71 s`.

5.2. Podzbiór do testu homomorficznego

Ze względu na koszt obliczeń homomorficznych test CKKS wykonano na zbalansowanym podzbiorze testowym MNIST:

Parametr	Wartość
Liczba klas	10
Liczba próbek na klasę	200
Łączna liczba próbek	2000

Dla każdej próbki szyfrowano wektor 784 pikseli, liczone score'y klas, odszyfrowywano wyniki i wybierano klasę przez `argmax`.


5.3. Wyniki klasyfikacji homomorficznej MNIST

Metryka	Wartość
Accuracy	0.8910
Precision weighted	0.8913
Recall weighted	0.8910
F1 weighted	0.8904

Czas wykonania(głównie deszyfrowania) przyspieszony przy pomocy multiprocessingu:

Miara	Wartość
Liczba procesów	4
Całkowity czas klasyfikacji homomorficznej	210.06 s
Średni czas na próbkę	0.1050 s

Macierz pomyłek dla MNIST CKKS:



6. Porównanie modelu jawnego i homomorficznego na tym samym podzbiorze

Porównanie nie odnosi się do pełnego testu MNIST, tylko dokładnie do tych samych 2000 próbek, które zostały poddane deszyfrowaniu.

Metryki modelu jawnego na podzbiorze:

Metryka	Wartość
Accuracy	0.8910
Precision weighted	0.8913
Recall weighted	0.8910
F1 weighted	0.8904

Porównanie predykcji:

Miara	Wartość
Zgodność predykcji jawnych i zaszyfrowanych	1.0000
Liczba różnych predykcji	0

Oznacza to, że dla wybranego podzbioru 2000 próbek predykcje po obliczeniach CKKS były identyczne z predykcjami modelu jawnego. Nie oznacza to jednak, że model osiąga 100% skuteczności względem etykiet prawdziwych. Skuteczność względem etykiet wynosi 0.8910, a zgodność 1.0000 dotyczy tylko porównania dwóch trybów inferencji: jawnego i homomorficznego.

7. Wnioski

1. Szyfrowanie homomorficzne CKKS pozwala wykonać liniową część predykcji bez odszyfrowywania danych wejściowych.
2. Dla modeli liniowych, takich jak regresja logistyczna lub liniowy klasyfikator SGD, obliczenie $w \cdot x + b$ dobrze pasuje do operacji wspieranych przez CKKS.
3. Na zbiorze Iris klasyfikacja homomorficzna dała poprawne wyniki i pełną skuteczność na testowanym zbiorze.
4. Na podzbiorze MNIST predykcje homomorficzne były zgodne z predykcjami modelu jawnego w 100% przypadków.
5. Błędy numeryczne CKKS były bardzo małe i nie zmieniły decyzji klasyfikatora w badanym teście.
6. Głównym ograniczeniem jest koszt obliczeniowy. Klasyfikacja 2000 próbek MNIST z użyciem 4 procesów trwała 210.06 s.

8. Podsumowanie

Projekt potwierdza, że można wykonać inferencję prostego klasyfikatora liniowego na danych zaszyfrowanych. Dla testowanego podzbioru MNIST wyniki CKKS po odszyfrowaniu były identyczne z predykcjami modelu jawnego, a błąd numeryczny był pomijalny z punktu widzenia decyzji klasyfikacyjnej. Jednocześnie rozwiązanie jest znacznie wolniejsze (ze względu na złożoność obliczeniową deszyfrowania) niż klasyczna predykcja na danych jawnych, dlatego w praktyce wymaga ograniczania liczby próbek, równoleglenia obliczeń lub dalszej optymalizacji.